

**ESCUELA POLITÉCNICA NACIONAL FACULTAD
DE INGENIERÍA EN SISTEMAS DE
INFORMACIÓN Y COMPUTACIÓN**



CARRERA:

CIENCIAS DE LA COMPUTACIÓN

PROYECTO DEL PRIMER BIMESTRE

**Diseño e Implementación de un Sistema de Recuperación de
Información**

Asignatura:

Recuperación de Información

Profesor:

Ing. Iván Carrera

Integrantes:

Alexis Bautista

Adrian Correa

Fecha:

01 de junio de 2026

1. Introducción

Los sistemas de recuperación de información (RI) son herramientas fundamentales para la localización precisa de documentos dentro de colecciones textuales masivas. Su utilidad es crítica en el análisis documental de inteligencia empresarial, bibliotecas digitales y motores de búsqueda.

Este informe detalla la arquitectura, el diseño de datos, la implementación y la evaluación analítica de un sistema de RI híbrido aplicado sobre un corpus estructurado de noticias. El problema abordado radica en estudiar el comportamiento de diferentes aproximaciones matemáticas al procesar índices textuales frente a distintas intenciones de búsqueda de un usuario.

2. Objetivos del Proyecto

2.1. Objetivo General

Diseñar, codificar e integrar un sistema modular funcional de recuperación de información en Python que permita la indexación de colecciones de documentos, el procesamiento de consultas y la medición científica de la efectividad de paradigmas clásicos y semánticos.

2.2. Objetivos Específicos

- Desarrollar de manera nativa los algoritmos clásicos de concordancia y pesos estadísticos de Jaccard, TF-IDF con similitud por coseno y BM25 para establecer las bases de la recuperación por coincidencia léxica.
- Integrar una solución de recuperación neuronal mediante la transformación de documentos a vectores de características densas utilizando el modelo preentrenado all-MiniLM-L6-v2 de Sentence-Transformers y la librería FAISS para optimizar las búsquedas vectoriales.
- Diseñar un módulo de análisis estadístico automatizado fundamentado en el estándar de juicios de relevancia qrels que permita calcular con rigor las métricas de Precision@K, Recall@K, Average Precision (AP) y Mean Average Precision (MAP).
- Determinar con base en los datos del experimento qué técnicas de indexación son superiores para búsquedas de palabras clave exactas y cuáles aportan mayor resiliencia frente a la sinonimia o consultas conceptuales en lenguaje natural.

3. Descripción del Corpus Utilizado

El sistema se alimenta de colecciones y particiones de entrenamiento y test extraídas del conjunto de datos Reuters-21578, un estándar en la evaluación de sistemas de ordenamiento textual y clasificación de noticias.

3.1. Estructura y Componentes

Los datos se procesan a partir de archivos en formato CSV. Con el fin de evitar el sobreajuste y garantizar una validación ciega y estricta, se emplea el archivo ModApte_test.csv para la fase de pruebas y evaluación masiva. Cada registro contiene el campo text (cuerpo de la noticia) y el campo topics (etiquetas temáticas asignadas por expertos). Estas etiquetas se extraen sistemáticamente para construir los juicios de relevancia u organizaciones qrels del sistema.

3.2. Estadísticas Generales del Dataset

A partir del entorno de ejecución y carga de datos del proyecto, se determinaron los siguientes indicadores:

- Número de registros en la partición de prueba procesada: 3,023 documentos individuales indexados para evaluación.

- Volumen histórico de documentos en el corpus completo: 51,081 documentos cargados en el flujo de preprocesamiento.
- Dimensión del espacio semántico: Embeddings densos con un tamaño vectorial fijo de 384 características por documento.

4. Explicación de las Decisiones de Diseño

El sistema se concibió bajo una arquitectura de diseño modular en Python para separar de forma limpia las responsabilidades de preprocesamiento, indexación, cálculo de relevancia y evaluación.

4.1. Pipeline de Preprocesamiento Diferenciado

Se aplicó un pipeline léxico (minúsculas, tokenización, remoción de stopwords con NLTK y PorterStemmer) para los modelos estadísticos, mientras que para el modelo neuronal se conservó la sintaxis y puntuación original, permitiendo que los embeddings capturen el contexto semántico completo."

4.2. Estructuras de Indexación y Modelos de Búsqueda

- Índice Invertido: Se construyó desde cero una estructura de diccionario indexado que mapea cada término extraído del corpus hacia una lista de tuplas con los identificadores de documentos y sus frecuencias locales (tf), optimizando los tiempos de respuesta en consultas léxicas masivas.
- Parámetros de BM25: Se configuraron las constantes estándar de saturación de términos y penalización por longitud de documento en $k1 = 1.5$ y $b = 0.75$ respectivamente.
- Indexación Vectorial (FAISS): Para el enfoque semántico, se transformaron los documentos en vectores densos utilizando el modelo preentrenado all-MiniLM-L6-v2. La búsqueda rápida de similitud en alta dimensionalidad se delegó a la librería FAISS, configurada con un índice plano euclidiano (IndexFlatL2).

5. Ejemplos de Consultas y Resultados

Para verificar el comportamiento analítico del sistema, se ejecutaron pruebas con consultas temáticas basadas en las categorías del corpus (como earn, acq, crude, trade, money-fx, grain, cocoa). A continuación, se ilustra una muestra del comportamiento del ranking (Top 3 documentos recuperados) para las palabras clave del sistema:

Consulta	Modelo	Documento Top 1	Documento Top 2	Tipo de Puntuación
earn	Jaccard	10003	11069	Similitud porcentual binaria
earn	TF-IDF	31319	36805	Similitud Coseno continua
earn	BM25	9847	23017	Puntuación probabilística
earn	Semántico	7983	20370	Similitud Semántica Vectorial

5.1. Contraste Empírico mediante Consulta en Lenguaje Natural Para evidenciar las diferencias prácticas entre la recuperación léxica y la representación densa, se ejecutó una consulta extensa y contextual: *"reports on company earnings, quarterly profits and banking sector"*. El objetivo fue analizar

cómo cada modelo interpreta una intención de búsqueda compleja. Se observaron los siguientes comportamientos:

- **Comportamiento del Modelo Léxico (BM25):** El algoritmo demostró una precisión literal excepcional. Su Top 3 (documentos duplicados) recuperó un cable sobre el *Royal Bank of Canada* informando una caída en sus ganancias del primer trimestre ("*19 pct drop in first quarter earnings*"). BM25 logró una relevancia alta porque el vocabulario de la consulta coincidió exactamente con la jerga periodística del texto ("quarter", "earnings", "reporting", "Bank").
- **Comportamiento del Modelo Semántico (Transformers + FAISS):** El motor demostró su capacidad de abstracción al recuperar documentos que abordan el contexto financiero sin depender de una coincidencia exacta de caracteres. Su Top 1 recuperó un texto sobre el Ministerio de Finanzas analizando cambios en las normativas de divulgación corporativa para inversores ("*corporate disclosure rules to provide more information for investors*"), lo cual representa el concepto subyacente de un reporte de ganancias. Su Top 3 recuperó directamente un balance financiero crudo con utilidades netas ("*Group net profit 45.2 mln*").

Este contraste demuestra que el modelo clásico (BM25) es sumamente efectivo cuando el usuario conoce y utiliza el vocabulario exacto de los documentos (coincidencia dura). En contraste, el modelo semántico (FAISS) actúa como un puente conceptual, siendo capaz de mapear una consulta sobre "reportes de ganancias" hacia documentos que hablan de "reglas de divulgación" o "utilidades netas", demostrando su resiliencia ante la sinonimia y el lenguaje descriptivo.

6. Análisis de Métricas de Evaluación

La evaluación cuantitativa se consolidó promediando los resultados de las consultas del experimento sobre la matriz de relevancia extraída de la partición ModApte_test.csv, configurando el límite del ranking en un valor fijo de K=10.

6.1. Matriz Resumida de Rendimiento (Métricas en K=10)

Modelo Evaluado	Mean Average Precision (MAP@10)	Precision Promedio@10	Recall Promedio@10
TF-IDF	0.009780	0.385714	0.012626
BM25	0.007458	0.414286	0.009903
Semántico (FAISS)	0.002923	0.385714	0.007970
Jaccard	0.000724	0.200000	0.000898

6.2. Discusión Analítica de Resultados

1. **Supremacía de los Modelos Léxicos Clásicos:** El modelo TF-IDF obtuvo el mejor desempeño general, seguido muy de cerca por BM25. Esto se explica porque las consultas evaluadas corresponden exactamente a los términos temáticos y literales asignados en la columna topics de Reuters. Los modelos de coincidencia exacta sobresalen ante este tipo de términos literales e indexados.

2. Rendimiento del Enfoque Semántico: La recuperación semántica con embeddings obtuvo valores más bajos en esta prueba automatizada de palabras clave únicas. Esto demuestra que cuando las consultas carecen de lenguaje natural complejo, paráfrasis o sinónimos conceptuales, la compresión en espacios vectoriales densos diluye la fuerza de los términos de búsqueda exactos, rindiendo por debajo de las ponderaciones estadísticas tradicionales.
3. Debilidad del Baseline (Jaccard): El modelo Jaccard representó el eslabón más débil del experimento debido a su enfoque puramente binario. Al ignorar la frecuencia interna de los términos en las noticias y la rareza global de las palabras en el corpus, presenta una capacidad de discriminación sumamente baja al acotar los resultados al Top 10.

7. Conclusiones y Recomendaciones

7.1. Conclusiones

- Se logró diseñar e implementar con éxito un sistema modular capaz de procesar colecciones masivas, indexar de manera tradicional y vectorial, y computar métricas automatizadas de RI bajo el estándar qrels.
- Los datos experimentales demuestran que BM25 y TF-IDF constituyen las mejores opciones para búsquedas temáticas directas basadas en términos exactos dentro de colecciones estructuradas de noticias.
- La recuperación semántica representa una alternativa complementaria que suele ser más útil cuando la consulta es más abierta, natural o utiliza sinónimos que no aparecen escritos de forma literal en los documentos.

7.2. Recomendaciones

1. Sustitución de Stemming por Lematización: Evaluar el uso de analizadores morfológicos avanzados en el pipeline clásico para reducir palabras a su lema en lugar de un truncamiento abrupto.
2. Optimización de Hiperparámetros: Realizar un ajuste fino sobre los parámetros k_1 y b de BM25 para adaptarlos exactamente a la distribución de longitud de documentos del corpus.
3. Modelos Híbridos (Ensemble): Implementar un sistema de ordenamiento en dos fases, usando BM25 como un filtro rápido de alta cobertura y el modelo semántico para reordenar el Top final.

8. Bibliografía

- Baeza-Yates R., Ribeiro-Neto B. , 2010. Modern Information Retrieval, The Concepts and Technology Behind Search.. Lugar de publicación: . EditorialAddison Wesley
- Baeza-Yates, R., & Ribeiro-Neto, B. *Modern Information Retrieval*. Pearson.
- -Manning C., Raghavan P., Schütze H. , 2008. Introduction to Information Retrieval. Lugar de publicación: . EditorialCambridge University Press
- Documentación Oficial de NLTK: <https://www.nltk.org>
- Documentación de FAISS: <https://github.com/facebookresearch/faiss>
- Documentación de Sentence-Transformers: <https://www.sbert.net>